

Самостійна робота 1

Биліна О., 4 курс, комп-мат-2

18.09.2026

1 Кластеризація на основі центроїдних методів

1.1 Підготовка до виконання завдання

За допомогою вбудованої в R функції `read.table` прочитано файл текстового формату і перетворено у формат таблиці `data.frame` для подальшого використання функціями для кластеризації.

1.2 Кластеризація

В роботі використано 3 центроїдні методи кластеризації: метод Ллойда, метод Макквіна та метод Хартігана-Вонга. Для всіх видів використовується вбудована функція `kmeans`. Реалізація кожного методу не відрізняється нічим окрім відповідного поля з назвою методу. За умовою, методи виконуються для різних варіантів кількості кластерів: від 2 до 20. Центри були обрані в кількості 50, оскільки така кількість була наведена у прикладі в завданні. Для збереження детермінованості результатів виставляється `set.seed(12345)`, що зумовлює вибір програмою одних і тих самих початкових центрів. Для кожного варіанту кількості кластерів у векторі зберігається відповідна внутрішньокластерна сума:

$$WSS = \sum_{r=1}^k \sum_{x_i \in C_r} |x_i - \mu_r|^2$$

За допомогою вбудованої функції `plot` відмальовуються графіки для кожного методу, в яких відображена внутрішньокластерна сума відповідно до кожного варіанту кількості кластерів для подальшого визначення оптимальної кількості кластерів. Нижче наведені графіки для трьох методів.




Figure 1: Графік залежності WSS від кількості кластерів




Figure 2: Графік залежності WSS від кількості кластерів




Figure 3: Графік залежності WSS від кількості кластерів

1.3 Вибір оптимальної кількості кластерів

Для всіх трьох методів видно, що кількість кластерів, в якій чітко можна побачити "лікоть", де сума різко зменшилась, а графік утворив помітний кут, дорівнює трьом. Отже обираю в якості оптимальної кількості кластерів 3. Ще рах роблю кластеризацію з такою кількістю кластерів для подальших завдань.

1.4 Індекс Ренда та виправлений індекс Ренда

Індекс Ренда демонструє кількість пар, що в різних розбиттях на кластери узгоджуються і рахується за формулою:

$$RI = \frac{a + b}{a + b + c + d}$$

, де

- a — пара знаходиться в одному кластері в обох розбиттях;
- b — пара знаходиться в різних кластерах в обох розбиттях;
- c — пара знаходиться в одному кластері в першому розбитті, але в різних кластерах у другому;
- d — пара знаходиться в різних кластерах у першому розбитті, але в одному кластері у другому.

Відповідна формула реалізована в коді вручну під назвою `rand_index`.

Виправлений індекс Ренда оцінює подібність двох кластерних розбиттів, враховуючи можливі випадкові збіги між ними і рахується за формулою:

$$ARI = \frac{\sum_{ij} n_{ij}^2 - \frac{(\sum_i a_i^2)(\sum_j b_j^2)}{n^2}}{\frac{1}{2} \left[\sum_i a_i^2 + \sum_j b_j^2 \right] - \frac{(\sum_i a_i^2)(\sum_j b_j^2)}{n^2}}$$

Відповідна формула реалізована в коді вручну під назвою `adjusted_rand_index`.

1.4.1 Результати

Було пораховано індекс Ренда та виправлений індекс Ренда для всіх пар розбиттів зроблених різними методами (як вище зазначено, для кількості кластерів 3). І індекси Ренда, і виправлені індекси Ренда для всіх пар дорівнюють 1, що означає абсолютну відповідність між кластерами, в яких знаходиться кожний об'єкт.

1.5 Матричні діаграми розсіювання

За допомогою вбудованої функції `pairs` створені матричні діаграми розсіювання для кожного методу, де на кожному підзображенні основного зображення об'єкти відмальовуються за різними парами характеристик. Об'єкти одного кластеру замальовані в один колір, кожному кластеру відповідає свій колір.




Figure 4: Матрична діаграма розсіювання




Figure 5: Матрична діаграма розсіювання




Figure 6: Матрична діаграма розсіювання

1.5.1 Результати

Як бачимо, розбиття на саме таку кількість кластерів має сенс і є логічним. Проте розбиття не є сильно деталізованим і помітно, що можна було б досягти більш точного результату при використанні більшої кількості кластерів. Також видно, що індекси Ренда та виправлені індекси Ренда дали правильний результат - розбиття на кластери абсолютно ідентичні. Для подальшого порівняння обираю розбиття методом Ллойда, адже цей метод є найбільш розповсюдженим. Зробити вибір на основі отриманих результатів не є можливим, адже результати ідентичні.

2 Кластеризація на основі медоїдних методів

2.1 Кластеризація

Для кластеризації на основі медоїдних методів використано алгоритм РАМ з бібліотеки cluster. В роботі використано три способи визначення відстані між об'єктами: евклідову відстань, відстань Манхеттена та максимальну відстань. Для кожного варіанту кількості кластерів від 2 до 20 визначається середнє значення ширини силуету. Ширина силуету для одного об'єкта рахується за формулою:

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))},$$

де $a(i)$ - середня відстань від об'єкта до інших об'єктів його кластера, а $b(i)$ - найменша середня відстань до об'єктів іншого кластера. Чим ближче середнє значення ширини силуету до 1, тим краще об'єкти розподілені по кластерах. За допомогою функції plot відмальовуються графіки залежності середнього значення ширини силуету від кількості кластерів для кожного способу визначення відстані. Нижче наведені отримані графіки.




Figure 7: Графік середнього значення ширини силуету для евклідової відстані




Figure 8: Графік середнього значення ширини силуету для відстані Манхеттена




Figure 9: Графік середнього значення ширини силуету для максимальної відстані

2.2 Вибір оптимальної кількості кластерів

Для всіх трьох способів визначення відстані найбільше середнє значення ширини силуету спостерігається при кількості кластерів 11, тому в якості основної кількості кластерів обираю 11. При цьому при кількості кластерів 3 значення силуету також є достатньо високим і не настільки сильно відрізняється від максимального. Такий результат узгоджується з графіками для центроїдних методів: на них найбільш помітний лікоть знаходиться при кількості кластерів 3, але приблизно після 11 кластерів внутрішньокластерна сума вже майже перестає зменшуватися. Тому можна вважати, що 3 кластери описують більш загальне розбиття даних, а 11 кластерів - більш детальне. Основним для медоїдних методів залишаю розбиття на 11 кластерів, але додатково виконую розбиття на 3 кластери для порівняння з центроїдними методами.

2.3 Індекс Ренда та виправлений індекс Ренда

Для порівняння розбиттів, отриманих медоїдними методами, використано індекс Ренда та виправлений індекс Ренда, описані в попередній частині роботи. Індекси рахуються для всіх розбиттів, отриманих при використанні різних способів визначення відстані. Також будуються таблиці спряженості, щоб побачити відповідність між окремими кластерами.

2.3.1 Результати для 11 кластерів

Для кількості кластерів 11 індекс Ренда та виправлений індекс Ренда для всіх пар розбиттів дорівнюють 1. Отже розбиття, отримані при використанні евклідової відстані, відстані Манхеттена та максимальної відстані, є повністю однаковими.

2.3.2 Результати для 3 кластерів

Додатково ті самі обчислення виконуються для кількості кластерів 3. Результати також дорівнюють 1.

2.4 Матричні діаграми розсіювання

Аналогічним чином відмалюовує матричні діаграми розсіювання.




Figure 10: Матрична діаграма розсіювання для евклідової відстані




Figure 11: Матрична діаграма розсіювання для відстані Манхеттена




Figure 12: Матрична діаграма розсіювання для максимальної відстані

Додатково відмалюовані матричні діаграми для розбиття на 3 кластери.




Figure 13: Матрична діаграма розсіювання для евклідової відстані, 3 кластери




Figure 14: Матрична діаграма розсіювання для відстані Манхеттена, 3 кластери




Figure 15: Матрична діаграма розсіювання для максимальної відстані, 3 кластери

2.4.1 Результати

Як бачимо, розбиття на 11 кластерів добре відповідає графікам середньої ширини силуету, де саме в цій області отримані найбільші значення. При цьому розбиття на 3 кластери також виглядає логічним і показує більш загальний поділ об'єктів, що узгоджується з центроїдними методами, для яких саме при 3 кластерах було видно найбільш помітний лікоть. Отже результати для 3 та 11 обидва мають право на життя і показують різний рівень деталізації, але все ж розбиття на 11, на мою думку, виглядає більш логічним. Для медоїдних методів в якості основного лишаю розбиття на 11 кластерів.

2.5 Порівняння центроїдного та медоїдного розбиттів

Для порівняння центроїдного та медоїдного підходів використовую метод Ллойда та РАМ з евклідовою відстанню. Спочатку порівнюються основні розбиття: 3 кластери для методу Ллойда та 11 кластерів для РАМ. Для них рахуються індекс Ренда, виправлений індекс Ренда та таблиця спряженості. Додатково РАМ виконується для 3 кластерів, щоб при однаковій кількості кластерів перевірити, наскільки схожим є розподіл об'єктів між трьома основними групами. Для найкращого центроїдного розбиття на 3 кластери та найкращого медоїдного розбиття на 11 кластерів індекс Ренда та виправлений індекс Ренда дорівнюють 0.752 та 0.327 відповідно. Значення індексу Ренда показує, що значна частина пар об'єктів класифікується двома підходами однаково. Але значно менше значення виправленого індексу Ренда свідчить про те, що розбиття суттєво відрізняються за своєю структурою. Це узгоджується з різною кількістю кластерів: центроїдний метод виділяє три великі групи, а медоїдний метод поділяє дані на більшу кількість дрібніших кластерів.

3 Частина 2

3.1 Таблиці Келі

3.2 Кластеризація

Для виконання цього завдання була створена таблиця з персонажами серіала "Гра престолів" і відповідними конструктами у двох версіях: 12 персонажів і 10 конструктів та 47 персонажів і 30 конструктів. Друга версія таблиці була створена через негативні результати кластеризації першої і вважатиметься основною. Для кластеризації були обрані методи Хартігана-Вонга для центроїдного методу і РАМ з евклідовою відстанню для медоїдного. Реалізація кластеризації та допоміжних етапів була описана для першої частини завдання і є подібною для цього, тому тут не описана. Кластеризація здійснюється спочатку за персонажами, а далі за конструктами. Для розбиття на кластери за

персонажами було вираховано внутрішньокластерну суму і середню ширину силуету для кількості кластерів від 2 до 12. Нижче наведено графіки:




Figure 16: Внутрішньокластерна сума для кластеризації за персонажами методом Хартігана-Вонга




Figure 17: Внутрішньокластерна сума для кластеризації за персонажами методом РАМ з евклідовою відстанню

Як бачимо, результати невтішні: навіть найбільша кількість кластерів для центроїдного методу дає неймовірно велику внутрішньокластерну суму у декілька десятків тисяч. Результати медоїдного методу так само не демонструють хороший результат: максимум серед варіантів кластерів ледве сягає 0.25, а середнє коливається коло 0.17. В минулому завданні, де кластеризація була успішною внутрішньокластерна сума сягала кількох тисяч, а середня ширина силуету - аж 0.75. Вже зараз можна говорити про неуспішну кластеризацію. Аналогічно була спроба здійснити розбиття на кластери за конструктами з кількістю кластерів від 1 до 10:




Figure 18: Внутрішньокластерна сума для кластеризації за конструктами методом Хартігана-Вонга




Figure 19: Середня ширина силуету для кластеризації за конструктами методом РАМ з евклідовою відстанню

Результати трохи кращі за розбиття за персонажами: середня ширина силуету досягає близько 0.38, але це все ще недостатній результат для того, щоб розбиття на кластери було логічним. В подальшій роботі з цими даними аналізуватися будуть лише дані з кластеризації на основі конструктів.

3.3 Вибір кількості кластерів і коректність

Для центроїдного методу "лікоть" знаходиться в 4, а для медоїдного найбільший результат - в 9. Оскільки персонажів (характеристик) дуже багато, функція `pairs` не повертає повну картинку, тому `pairs` застосовується поетапно для різних характеристик. Нижче наведені матричні діаграми розсіювання для кількох характеристик для центроїдного методу з 4 кластерами й медоїдного з 9:




Figure 20: Матричні діаграми розсіювання для метода Хартігана-Вонга для деяких характеристик




Figure 21: Матричні діаграми розсіювання для метода Хартігана-Вонга для деяких характеристик




Figure 22: Матричні діаграми розсіювання для метода РАМ для деяких характеристик




Figure 23: Матричні діаграми розсіювання для метода РАМ для деяких характеристик

Видно, що алгоритми намагаються кластеризувати дані - купки об'єктів збираються разом, але в цілому всі дані більш нагадують конфетті, ніж дані, які можна логічно розбити на кластери. Тож вважаю, що цей набір даних кластеризується погано і переходжу до наступного варіанта набору даних.

4 Кластеризація даних Numbeo

4.1 Підготовка даних

В якості наступного набору даних були обрані дані з сайту Numbeo про ціни в різних містах світу. В таблиці міститься 20 міст і 6 характеристик: ціна обіду в недорогому ресторані, капучино, літра молока, 12 яєць, місячного інтернету та оренди однокімнатної квартири в центрі міста. Оскільки значення різних характеристик дуже відрізняються за масштабом, перед кластеризацією дані були стандартизовані за допомогою функції `scale`. Для кластеризації знову обрані метод Хартігана-Вонга і РАМ з евклідовою відстанню.

4.2 Вибір кількості кластерів

Для методу Хартігана-Вонга була порахована внутрішньокластерна сума для кількості кластерів від 2 до 12. Для РАМ аналогічно була порахована середня ширина силуету. Нижче наведені отримані графіки.




Figure 24: Внутрішньокластерна сума для кластеризації методом Хартігана-Вонга




Figure 25: Середня ширина силуету для кластеризації методом РАМ з евклідовою відстанню

Для центроїдного методу найбільш логічним виглядає розбиття приблизно на 5 кластерів: до цього значення внутрішньокластерна сума зменшується достатньо швидко, а далі зниження стає більш плавним. Для РАМ найбільше значення середньої ширини силуету спостерігається при 2 кластерах, але також добре видно локальне підвищення при 5-6 кластерах, при цьому значення для 5 кластерів є достатньо високим. Оскільки розбиття на 2 кластери є дуже загальним, а результат при 5 також узгоджується з графіком центроїдного методу, для обох методів обираю 5 кластерів.

4.3 Матричні діаграми розсіювання

Аналогічно попереднім завданням за допомогою функції `pairs` були побудовані матричні діаграми розсіювання. Об'єкти одного кластеру замальовані одним кольором, а кожному кластеру відповідає свій колір.




Figure 26: Матрична діаграма розсіювання для методу Хартігана-Вонга




Figure 27: Матрична діаграма розсіювання для методу РАМ з евклідовою відстанню

Як бачимо, на відміну від таблиці Келі, в цьому випадку розбиття виглядає значно логічніше. На багатьох парах характеристик об'єкти одного кольору знаходяться близько один до одного, а між окремими групами видно певне розділення. Також матричні діаграми для двох методів дуже схожі, хоча розподіл деяких об'єктів все ж відрізняється.

4.4 Порівняння результатів

Для порівняння розбиттів методом Хартігана-Вонга і РАМ були порашовані індекс Ренда та виправлений індекс Ренда. Індекс Ренда дорівнює 0.926, а виправлений індекс Ренда - 0.77. Виправлений

індекс Ренда також є достатньо високим, тому результати двох методів можна вважати дуже схожими, хоча вони і не є повністю ідентичними. Це також видно на матричних діаграмах розсіювання, де основні групи об'єктів зберігаються в обох випадках. Отже цей набір даних кластеризується значно краще за таблицю Келі. Обидва методи дають достатньо схожі результати при розбитті на 5 кластерів, що підтверджується як візуально матричними діаграмами розсіювання, так і значеннями індексу Ренда та виправленого індексу Ренда.

4.5 Використання штучного інтелекту

В роботі штучний інтелект (ChatGPT) був використаний для: знаходження інформації про формули індекса Ренда та виправленого індекса Ренда, про побудову графіків на мові R і взагалі про деталі використання мови, про деталі використання LaTeX для написання звіту; оформлення даних з Numbeo в csv-таблицю. Код та звіт були написані самостійно без використання штучного інтелекту.